Московский Государственный Университет им. М.В. Ломоносова
Факультет Вычислительной Математики и Кибернетики
Кафедра Автоматизации Систем Вычислительных Комплексов

Задание по курсу "Распределённые системы"

Отчёт

Выполнил:
Ушаков Иван Кириллович
421 группа

Москва, 2022 год

Содержание

1. Постановка задач

1.1. Задача 1: моделирование

В транспьютерной матрице размером $4 * 4$, в каждом узле которой находится один процесс, необходимо выполнить операцию редукции MPI_MINLOC, определить глобальный минимум и соответствующих ему индексов. Каждый процесс предоставляет свое значение и свой номер в группе. Для всех процессов операция редукции должна возвратить значение минимума и номер первого процесса с этим значением. Реализовать программу, моделирующую выполнение данной операции на транспьютерной матрице при помощи пересылок MPI типа точка-точка. Оценить сколько времени потребуется для выполнения операции редукции, если все процессы выдали эту операцию редукции одновременно. Время старта равно 100, время передачи байта равно 1 ($Ts = 100, Tb = 1$). Процессорные операции, включая чтение из памяти и запись в память, считаются бесконечно быстрыми.

1.2. Задача 2: надёжность

Доработать MPI-программу, реализованную в рамках курса “Суперкомпьютеры и параллельная обработка данных”. Добавить контрольные точки для продолжения работы программы в случае сбоя. Реализовать один из 3-х сценариев работы после сбоя: а) продолжить работу программы только на “исправных” процессах; б) вместо процессов, вышедших из строя, создать новые MPI-процессы, которые необходимо использовать для продолжения расчетов; в) при запуске программы на счет сразу запустить некоторое дополнительное количество MPI-процессов, которые использовать в случае сбоя.

В данной задаче был выбран вариант "а".

2. Пояснения к решениям

2.1. Моделирование

В транспьютерной матрице размером $4 * 4$, в каждом узле которой находится один процесс, необходимо выполнить операцию нахождения минимального значения и его координат среди 16 чисел. А предложенном алгоритме необходиммо сделать 4 шага, чтобы определить минимум и его координаты. Это количество шагов является минимальным для поставленной задачи. Способ реализации:

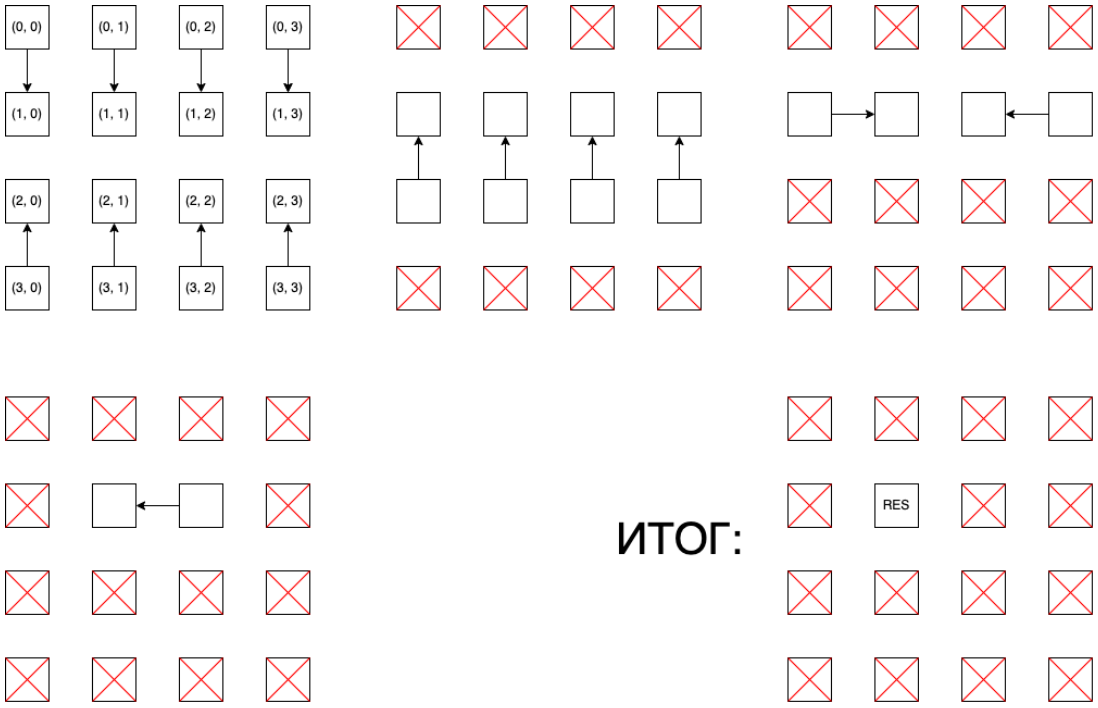

Данный алгоритм был реализован с помощью функций MPI_Send и MPI_Recv. Получение топологии в виде транспьютерной матрицы произведено с помощью функции MPI_Cart_rank. Оценим время работы алгоритма. Если время старта равно 100, время передачи байта равно 1 ($Ts = 100, Tb = 1$), то время выполнения операции рассчитывается следующим образом:

$$time = num\_steps(Ts + nTb)$$

где n - размер передаваемого сообщения в байтах. В нашем случае сообщением является число, размер которого может быть равен, 8 байтам (указатель на массив). Таким образом, при n = 12, получаем:

$$time = 4(100 + 8 * 1) = 432$$

Пересылка сообщений была организована с помощью двух функций, которые передавали по заданному "rank"процесса:

```
void send_coords_and_value(int coords[2], int value, int other_coords[2], int other_rank, MPI_Comm comm) {
    MPI_Send(coords, 2, MPI_INT, other_rank, 0, comm);
    MPI_Send(&value, 1, MPI_INT, other_rank, 0, comm);
}
void receive_coords_and_value(int coords[2], int *value, int *other_coords, int other_rank, MPI_Comm comm){
    MPI_Recv(other_coords, 2, MPI_INT, other_rank, 0, comm, MPI_STATUS_IGNORE);
    MPI_Recv(value, 1, MPI_INT, other_rank, 0, comm, MPI_STATUS_IGNORE);
}
```

Создание транспьютерной матрицы с помощью *MPI_ Cart_ create*:

```
MPI_Cart_create(MPI_COMM_WORLD, 2, size, periodic, 0, &comm);
```

На первом шаге алгоритма мы пересылаем сообщения из первого ряда во второй и из четвёртого в третий. Поэтому в 0 и 3 координате по вертикали мы вызываем функцию *send_ coords_ and_ value*, а в 1 и 2 координате по вертикале мы вызываем функцию *receive_ coords_ and_ value*. Таким образом процессы в 0 и 3 строке отправляют текущий минимум в строки 1 и 2, а те их получают и заменяют минимум и координаты минимума в случае необходимости. Функция *MPI_ Cart_ rank* позволяет получить rank процесса по его координатам. Аналогично в остальных шагах.

Первый шаг:

```
other_coords[1] = coords[1];

    switch(coords[0]) {
        case 0:
            other_coords[0] = coords[0] + 1;
            MPI_Cart_rank(comm, other_coords, &other_rank);
            send_coords_and_value(result_coords, a, other_coords, other_rank, comm);
        break;
        case 3:
            other_coords[0] = coords[0] - 1;
            MPI_Cart_rank(comm, other_coords, &other_rank);
            send_coords_and_value(result_coords, a, other_coords, other_rank, comm);
        break;

        case 1:
            other_coords[0] = coords[0] - 1;
```

```
            MPI_Cart_rank(comm, other_coords, &other_rank);
            receive_coords_and_value(coords, &result, other_coords, other_rank, comm);
            goto Better_res;
        break;
        case 2:
            other_coords[0] = coords[0] + 1;
            MPI_Cart_rank(comm, other_coords, &other_rank);
            receive_coords_and_value(coords, &result, other_coords, other_rank, comm);
        Better_res:
            if (result < a) {
                a = result;
                result_coords[0] = other_coords[0];
                result_coords[1] = other_coords[1];
            }
        break;
        default:
        break;
    }
    MPI_Barrier(comm);
```

Второй шаг алгоритма:

```
switch(coords[0]) {
        case 1:
            other_coords[0] = coords[0] + 1;
            MPI_Cart_rank(comm, other_coords, &other_rank);
            receive_coords_and_value(coords, &result, other_coords, other_rank, comm);

            if (result < a) {
                a = result;
                result_coords[0] = other_coords[0];
                result_coords[1] = other_coords[1];
            }
        break;
        case 2:
            other_coords[0] = coords[0] - 1;
            MPI_Cart_rank(comm, other_coords, &other_rank);
            send_coords_and_value(result_coords, a, other_coords, other_rank, comm);
        break;
        default:
        break;
    }
    MPI_Barrier(comm);
```

Третий шаг алгоритма:

```
if (coords[0] == 1 && (coords[1] == 0 || coords[1] == 3)) {
        other_coords[0] = coords[0];
        if (coords[1] == 0) {
            other_coords[1] = coords[1] + 1;
        } else {
            other_coords[1] = coords[1] - 1;
        }
        MPI_Cart_rank(comm, other_coords, &other_rank);
        send_coords_and_value(result_coords, a, other_coords, other_rank, comm);
    }

    if (coords[0] == 1 && (coords[1] == 1 || coords[1] == 2)) {
        other_coords[0] = coords[0];
        if (coords[1] == 1) {
            other_coords[1] = coords[1] - 1;
        } else {
            other_coords[1] = coords[1] + 1;
        }
        MPI_Cart_rank(comm, other_coords, &other_rank);
        receive_coords_and_value(coords, &result, other_coords, other_rank, comm);

        if (result < a) {
            a = result;
            result_coords[0] = other_coords[0];
            result_coords[1] = other_coords[1];
        }
    }
    MPI_Barrier(comm);
```

Четвёртый шаг алгоритма:

```
if (coords[0] == 1 && coords[1] == 3) {
        other_coords[0] = coords[0];
        other_coords[1] = 1;
        MPI_Cart_rank(comm, other_coords, &other_rank);
        send_coords_and_value(result_coords, a, other_coords, other_rank, comm);
    }
    if (coords[0] == 1 && coords[1] == 1) {
        other_coords[0] = coords[0];
        other_coords[1] = 3;
        MPI_Cart_rank(comm, other_coords, &other_rank);
        receive_coords_and_value(coords, &result, other_coords, other_rank, comm);
        if (result < a) {
            a = result;
            result_coords[0] = other_coords[0];
            result_coords[1] = other_coords[1];
        }
    }
    MPI_Barrier(comm);
```

После четырёх итераций ответ хранится в процессе с координатами (1, 1). Таким образом получаем ответ:

```
 if (coords[0] == 1 && coords[1] == 1) {
        printf("\n\nRESULTS:\n");
        printf("Min result: %d\n", a);
        printf("Min result coords: %d, %d\n", result_coords[0], result_coords[1]);
    }
```

2.2. Надёжность

Программа, написанная в рамках курса СКиПОД решала задачу вычисления интеграла методом Монте-Карло. При запуске должен быть задан параметр — количество итераций для рассчёта интеграла. Саму формулу можно изменить в исходниках программы:

```
long double cur_function(long double x)
{
    return x*x + x*x*x;
}
```

Для начала нам необходимо написать функцию, которая будет срабатывать в случае возникновения сбоя. В варианте *a)* задания после сбоя используются только исправные процессы. В функции-обработчике и происходит нахождение отказавшей задачи и повторный запуск уже с оставшимся количеством процессов:

```
static void errhandler(MPI_Comm* pcomm, int* perr, ...) {
    error_occured = 1;
    int err = *perr;
    char errstr[MPI_MAX_ERROR_STRING];
    int size, nf, len;
    MPI_Group group_f;
    /*
     Here we get nuymber of crashed processes, error type and change constant, to make formula correct
         without crashed processor
     */
    MPI_Comm_size(main_comm, &size);
    MPIX_Comm_failure_ack(main_comm);
    MPIX_Comm_failure_get_acked(main_comm, &group_f);
    MPI_Group_size(group_f, &nf);
    MPI_Error_string(err, errstr, &len);
    N -= nf*(N/numprocs);
    /*
     Create new communicator without crashed processor
     */
    MPIX_Comm_shrink(main_comm, &main_comm);
    MPI_Comm_rank(main_comm, &rank);
    MPI_Comm_size(main_comm,&numprocs);
```

Затем в функции main обозначить функцию как обработчик в случае ошибок:

```
  /*
   Set error handler
   */
   MPI_Errhandler errh;
   MPI_Comm_create_errhandler(errhandler, &errh);
   MPI_Comm_set_errhandler(main_comm, errh);
```

Необходимо также добавить контрольную точку, чтобы после расчётов, если выяснится, что произошёл сбой, то результат не может быть верным, из-за чего необходимо пересчитать данные на уже только исправных процессах:

```
  /*
     Summing everything in varaible drobSum and goto checkpoint
     if there was an error (because varaible numproc has changed)
   */
checkpoint:
   MPI_Barrier(main_comm);
   for (long long int j = 0; j < N/numprocs; j++){
       drobSum += cur_function(rand_point(leftBorder, rightBorder));
       if (error_occured == 1) {
           error_occured = 0;
           goto checkpoint;
       }
   }
   if (error_occured == 1) {
       error_occured = 0;
       goto checkpoint;
   }
```

Ну и последнее – это искусственно смоделировать отказ с помощью *SIGKILL*:

```
  /*
   Modelling fault
   */
   MPI_Barrier(main_comm);
   if (myid == KILLED_PROCESS) {
           raise(SIGKILL);
```

```
    }
    MPI_Barrier(main_comm);
```

В остальном интеграл продолжает считаться так же как и в задании из курса СКиПОД

3. Исходный код

В рамках задания по курсу "Распределённые системы"были реализованы две параллельные программы, исходный код которых можно найти в репозитории *https://github.com/Ushuaya/Skipod_2_or_Distributed_systemns.git*.
Кроме того, файлы с исходными текстами программ прикреплены в трекере на сайте *dvmh.keldysh.ru*.